

Sync2Act

混合模态数据损坏研究

完整真实数据集、六组消融、三个随机种子

实验规模	3数据集 × 6 消融 × 5 条件 × 3 seeds
完成状态	270 / 270 组成功完成并通过完整性审计
训练范围	完整 episode、完整 frame、全部相机；仅训练集损坏
核心指标	干净测试集 action MSE，以及相对同模型同 seed 干净基线的 MSE 比值
评估方式	同一模型、同一测试集上的第一步预测与因果时间集成配对评估
报告日期	2026-10-02

结论预览

在第一步预测评估中，当 action 标签发生错位或缺失时，正确对齐的 Oracle action-label quality 几乎消除了平均退化：Quality-Full 的相对 MSE 为 0.977×，而 ACT-Lite 为 2.432×。在综合损坏下，Quality-Full 将平均相对 MSE 从 1.535× 降至 1.144×。state quality 输入也有帮助，但 image quality 在当前离线指标上没有形成清晰收益。

时间集成评估：在同一模型与测试集上比较两种动作预测方式，分别报告相对于干净训练的 MSE 比值和集成前后的实际 MSE 变化。

1 研究问题与结论边界

本轮实验研究四种训练集混合质量情形：仅图像损坏、仅 state 损坏、仅 action 标签损坏，以及三种模态同时混合损坏。核心问题是：在训练数据中同时存在干净和损坏片段时，按模态拆分的质量信息应当作为模型输入、作为 loss 权重，还是二者同时使用。

实验中的 quality 是由已知合成损坏过程直接给出的 **Oracle quality**。它表示已知故障来源的元数据，分数是启发式映射，不是经过校准的正确概率或严格证明的性能上界，也不是部署时自动获得的传感器信号。所有结果均为干净测试集上的**离线动作预测**；MSE 与 MAE 不能替代真实机器人或仿真器中的闭环成功率、回报和安全失败率。

实验采用两种离线动作评估方式：第一步预测直接取每个动作块的首步，因果时间集成融合不同起点对同一时刻的预测。两种方式使用相同 checkpoint、测试 episodes 和归一化统计量。第 6 节分别给出两种方式的总体结果曲线，并列出实际 MSE 的配对变化。每条退化曲线以对应评估方式的干净训练结果为分母；集成前后变化以第一步预测结果为参照。

2 数据集与训练协议

三个公开机器人示范数据集均通过单任务检查。图像训练使用每个数据集的全部同步相机，而不是只选一个视角。数据先按 episode 固定划分，再只对训练 episodes 构造损坏，避免同一 episode 的相邻帧跨训练和测试泄漏。

数据集	Episode	Frame	相机	State / Action	Train / Val / Test
XArm Lift Medium	800	20,000	1	4 / 4	640 / 80 / 80
Koch Pick Place 1 Lego	100	32,951	2	6 / 6	80 / 10 / 10
ALOHA Static Battery	49	29,400	4	14 / 14	41 / 4 / 4

表 1: 完整数据集统计。训练分别使用 1、2、4 路同步相机。

统一配置为 10 epochs、CUDA、batch size 256、segment length 16、随机种子 7/17/27、划分种子 7。图像最长边缩放到 64 像素。Normalization statistics 只由干净 Training episodes 计算，并在同一数据集的 90 个组合间固定。验证集和测试集始终保持干净。

数据隔离与审计

270 个 run 均保存独立 checkpoint、预测 CSV、per-episode 指标和 run manifest。审计确认 checkpoint schema、quality schema、experiment signature 与 run metadata 一致；每个数据集只有一套 normalization statistics；没有缺失或重复组合。

3 混合损坏条件

每个 episode 被划分为连续 segment，再按权重互斥地分配到一个 component。同一 segment 不会同时被计入多个百分比桶。Temporal shift 使用 2 frames，边界位置标记为 missing；模态缺失将对应输入或标签置零，同时把该模态 quality 置为 0 并记录 missing mask 与 provenance。

训练条件	Segment 构成
Clean	100% clean
Mixed image damaged	50% clean + 40% image shift 2 + 10% image missing
Mixed state damaged	50% clean + 40% state shift 2 + 10% state missing
Mixed action damaged	50% clean + 40% action shift 2 + 10% action-label missing
Mixed three corruptions	20% clean + 20% image shift 2 + 20% state shift 2 + 25% action shift 2 + image/state/action missing 各 5%

表 2: 本轮正式实验的五个训练条件。

在所有数据集和 seeds 中, 实际 segment 比例与目标比例的最大偏差约为 0.03 个百分点。由于 episode 尾部 segment 长度可能不足 16, 按 frame 统计的比例存在小幅偏差: 单模态条件中各 component 的 frame 比例偏差不超过约 0.35 个百分点; 综合条件不超过约 0.83 个百分点。

4 六组 ACT / Quality 消融

模型	Quality 输入	Action-label 加 权 loss	目的
ACT-Lite	否	否	无质量信息的基线
Quality-Input	是	否	仅测试质量条件输入
Quality-Weighted-Loss	否	是	仅测试坏 action 标签降权
Quality-Full	是	是	完整方法
Quality-Shuffled	打乱	是	破坏质量与样本的对应关系
Quality-Constant	常数	是	所有样本伪装为干净

Image/state missing 不会自动删除整帧: 样本仍参加训练, 模型通过 observation quality 与 missing mask 得知输入不可靠。Action missing 则是标签可靠性问题; 只有使用 action-label quality 加权 loss 的模型才会降低或屏蔽该标签的监督贡献。

5 指标与汇总方法

主要指标是干净测试集上的 action mean squared error:

$$\text{MSE} = \frac{1}{Nd} \sum_{i=1}^N \|\hat{a}_i - a_i\|_2^2.$$

三个数据集的 action 单位和尺度不同, 因此跨数据集使用同一模型、同一 seed 的相对比值:

$$R = \frac{\text{MSE}_{\text{damaged train} \rightarrow \text{clean test}}}{\text{MSE}_{\text{clean train} \rightarrow \text{clean test}}}.$$

$R = 1$ 表示与干净训练持平, $R > 1$ 表示退化。下文的总体数字先在每个 dataset-model-seed 内计算 R , 再对 3 个数据集与 3 个 seeds 的 9 个比值取均值。

6 总体结果

6.1 第一步预测的总体结果




图 1: 三个数据集与三个 seeds 的平均相对 MSE。越低越好；虚线为干净训练基准。

模型	Image damaged	State damaged	Action damaged	Mixed
ACT-Lite	0.999	1.388	2.432	1.535
Quality-Input	0.995	1.234	2.394	2.007
Weighted-Loss	1.000	1.374	0.992	1.163
Quality-Full	0.996	1.238	0.977	1.144
Shuffled	1.004	1.449	2.463	1.538
Constant	0.994	1.303	2.401	1.500

表 3: 平均 MSE 比值。绿色仅标示列内最小值，不代表统计显著性。

6.2 时间集成后的总体结果

两种评估方式使用同一组 270 个 checkpoint、测试 episodes 和归一化统计量；decay=0.7 在评估前固定。只融合起点不晚于当前时刻的预测，并在每条 episode 边界重置历史。第一步预测一致性核对为 270/270 通过。两种评估方式采用相同的归一化规则：先在每个数据集、模型、seed 内，用该条件的测试 MSE 除以同一模型同一 seed 的干净训练测试 MSE，再平均 9 个比值。时间集成曲线的分子和分母均使用集成后的 MSE；两种方式的横轴、六模型配色和纵轴范围一致。

$$R_{\text{ens}} = \frac{\text{MSE}_{\text{damaged train, ens}}}{\text{MSE}_{\text{clean train, ens}}}.$$




图 2: 时间集成后的平均相对 MSE。每点平均 3 数据集与 3 seeds 的 9 个比值；虚线为时间集成后的干净训练基准。

模型	Image	State	Action	Mixed
ACT-Lite	1.0012	1.2514	2.1177	1.4070
Quality-Input	1.0015	1.1328	2.0711	1.6831
Weighted-Loss	1.0018	1.2465	1.0089	1.1215
Quality-Full	1.0022	1.1360	1.0002	1.0970
Shuffled	1.0091	1.2636	2.1074	1.3787
Constant	0.9999	1.1959	2.0747	1.3916

表 4: 时间集成的平均 MSE 比值，衡量相对于干净训练的退化程度。集成前后的实际误差变化见配对比较。

6.3 集成前后的 MSE 变化

下表逐运行计算 $100 \times (\text{集成后 MSE} / \text{未集成 MSE} - 1)$ ，再对 3 数据集 $\times$ 3 seeds 取平均。负数表示 MSE 降低，正数表示 MSE 增加；不跨机器人直接平均原始 MSE。

模型	Clean	Image	State	Action	Mixed
ACT-Lite	+27.37%	+27.72%	+15.23%	+11.47%	+16.74%
Quality-Input	+27.65%	+28.58%	+17.27%	+11.29%	+8.59%
Weighted-Loss	+27.32%	+27.68%	+15.87%	+29.56%	+22.52%
Quality-Full	+27.67%	+28.46%	+17.22%	+31.16%	+22.64%
Shuffled	+27.51%	+28.10%	+11.55%	+10.29%	+14.60%
Constant	+27.58%	+28.29%	+17.16%	+11.10%	+17.89%

表 5: 实际 MSE 的平均配对变化百分比。每格 9 次运行；正数表示误差增加。

下表在同一数据集、同一模型内对五个训练条件和三个 seeds 的 15 次运行取平均。MSE 差值 = 集成后均值 - 未集成均值；变化 (%) = $100 \times (\text{集成后均值} / \text{未集成均值} - 1)$ 。此处的均值之比不同于上表逐运行百分比的均值。

数据集	模型	未集成 MSE	集成后 MSE	MSE 差值	变化
XArm	ACT-Lite	0.39085	0.39331	+0.002467	+0.63%
XArm	Quality-Input	0.39089	0.39226	+0.001367	+0.35%
XArm	Weighted-Loss	0.38469	0.38938	+0.004692	+1.22%
XArm	Quality-Full	0.38362	0.38759	+0.003975	+1.04%
XArm	Shuffled	0.39163	0.39363	+0.001998	+0.51%
XArm	Constant	0.39087	0.39338	+0.002507	+0.64%
Koch	ACT-Lite	11.986	16.958	+4.972	+41.48%
Koch	Quality-Input	13.35	18.178	+4.828	+36.16%
Koch	Weighted-Loss	8.224	12.919	+4.695	+57.08%
Koch	Quality-Full	8.1593	12.941	+4.781	+58.60%
Koch	Shuffled	12.532	17.4	+4.867	+38.84%
Koch	Constant	11.936	16.915	+4.978	+41.71%
ALOHA	ACT-Lite	0.0004896	0.00053513	+4.553e-05	+9.30%
ALOHA	Quality-Input	0.00050224	0.00054808	+4.584e-05	+9.13%
ALOHA	Weighted-Loss	0.00033546	0.00037695	+4.149e-05	+12.37%
ALOHA	Quality-Full	0.00031741	0.00036239	+4.498e-05	+14.17%
ALOHA	Shuffled	0.00050376	0.00054189	+3.813e-05	+7.57%
ALOHA	Constant	0.00048196	0.00053488	+5.292e-05	+10.98%

表 6: 同一数据集内的实际 MSE 对照。每行平均五条件、三 seeds，共 15 次运行。

270 组逐运行 MSE 相对变化的平均值为 +21.20%。相对退化曲线下降不等于实际 MSE 下降：时间集成也会改变作为分母的干净训练基线。判断是否更准确，应同时查看未集成与集成后的实际 MSE。结果仅限离线动作预测。完整条件对照见 HTML 可展开表格及 `temporal_ensemble/mse_by_dataset_model_condition.csv`。复现：`python tools/evaluate_temporal_study.py --device cuda --decay 0.7 --report-only`。

7 按故障模态解读

本节及第 8 节的模态分析与模型配对采用第一步预测指标；时间集成的总体结果与两种评估方式的 MSE 对照见第 6 节。

7.1 Action 标签损坏：加权 loss 是关键

ACT-Lite 在 action-damaged 条件下平均退化到 $2.432\times$ ，Quality-Input 仍为 $2.394\times$ 。Quality-Input 只接收观测质量，并不知道动作标签质量；只要错误标签继续以普通权重进入 loss，监督信号仍会把模型拉向错误目标。

Quality-Weighted-Loss 将比值降至 $0.992\times$ ，Quality-Full 为 $0.977\times$ 。Shuffled 与 Constant 分别退化到 $2.463\times$ 和 $2.401\times$ ，这些对照支持正确对齐的逐样本 **action-label quality** 的重要性，不能仅将收益归因于额外输入维度、随机降权或模型容量。

模型	XArm MSE	Koch MSE	ALOHA MSE
ACT-Lite	0.406790	21.5804	0.0009031
Quality-Input	0.405661	21.4460	0.0009163
Weighted-Loss	0.388007	7.3369	0.0002718
Quality-Full	0.387742	7.3168	0.0002662
Shuffled	0.407930	21.8305	0.0009603
Constant	0.406804	21.5116	0.0009184

表 7: Mixed action damaged 的三-seed 平均绝对 MSE。不同数据集之间不可横向比较数值大小。

7.2 State 观测损坏：quality 输入有帮助但不完全

State damaged 使 ACT-Lite 平均退化到 $1.388\times$ 。Quality-Input 和 Quality-Full 分别为 $1.234\times$ 与 $1.238\times$ ，优于不使用 observation quality 的 Weighted-Loss ($1.374\times$)。然而两者仍明显高于 1，说明 quality 元数据只能帮助模型识别不可靠 state，并不能恢复被错位或置零的信息。

7.3 Image 观测损坏：当前离线指标不敏感

所有模型在 image-damaged 条件下都约为 $1.0\times$ 。正确 image quality、打乱 quality 和恒定 quality 之间没有稳定差距。这个结果只能说明在当前 64 像素输入、所选任务与离线 action MSE 下，40% 两帧图像错位加 10% 全相机缺失没有形成可辨别的平均退化；不能据此断言真实闭环控制对视觉故障不敏感。

7.4 综合损坏：主要收益来自处理坏 action 标签

综合条件下，ACT-Lite 为 $1.535\times$ ，Quality-Input 反而达到 $2.007\times$ ；Weighted-Loss 与 Quality-Full 分别降至 $1.163\times$ 和 $1.144\times$ 。Full 仅比 Weighted-Loss 略好，说明主要收益仍来自 action-label weighting，observation quality 的额外贡献较小且随 seed 波动。

8 数据集差异与配对比较

数据集	模型	Image	State	Action	Mixed
XArm Lift	ACT-Lite	1.000	1.024	1.073	1.059
	Quality-Full	1.000	1.013	1.024	1.029
Koch Pick Place	ACT-Lite	1.000	1.467	2.958	1.774
	Quality-Full	1.017	1.270	0.964	1.123
ALOHA Battery	ACT-Lite	0.997	1.674	3.265	1.773
	Quality-Full	0.973	1.430	0.942	1.279

表 8: 按数据集汇总的三-seed 平均 MSE 比值。

XArm 对本轮损坏整体较不敏感；Koch 与 ALOHA 的 state/action 损坏更明显。因此不能只用一个数据集判断质量机制。Quality-Full 相对 ACT-Lite 在 36 个损坏配对中有 31 个获得更低绝对 MSE，按各自 clean 基线归一化后也是 31/36。相对 Shuffled 为 32/36 个更低绝对 MSE，相对 Constant 为 29/36。

比较	Full 更低绝对 MSE	Full 更低相对比值	总配对数
Quality-Full vs ACT-Lite	31	31	36
Quality-Full vs Shuffled	32	31	36
Quality-Full vs Constant	29	29	36
Quality-Full vs Quality-Input	29	28	36
Quality-Full vs Weighted-Loss	23	24	36

9 结论与下一步

主要结论

1. **Oracle action-label quality** 有效。它在 Koch 与 ALOHA 上大幅消除 action shift/missing 带来的退化，并通过 shuffled/constant 控制验证了对齐信息的重要性。
2. **State quality** 输入有中等收益。它降低了 state-damaged 的平均误差，但无法恢复缺失信息，结果仍差于 clean。
3. **Image quality** 暂无清晰收益。当前损坏强度、图像分辨率和离线 action MSE 可能不足以显现闭环视觉风险。
4. **Quality-Full** 对综合损坏最稳健。但它相对仅 Weighted-Loss 的优势较小，主要提升仍来自 action-label weighting。
5. 固定 **decay=0.7** 的时间集成未降低总体实际 MSE。270 组逐运行 MSE 变化百分比的均值为 +21.20%；退化比值下降不能代替实际误差改善，也不构成闭环控制收益的证据。

建议下一阶段按以下顺序推进：

1. 用已知 corruption provenance 训练自动质量估计器，分别预测 image/state/action-label quality，并报告校准误差；
2. 用预测 quality 替换 Oracle quality，量化质量估计误差对性能的影响；
3. 提高 image shift/missing 的严重度和持续时间，并保留高分辨率视觉特征，判断当前“近似无影响”是否由实验灵敏度不足造成；
4. 在仿真或真实机器人上做闭环 rollout，报告成功率、安全失败类型和恢复行为；
5. 若闭环趋势仍成立，再扩展更多 seeds、任务与损坏强度，并使用配对置信区间或显著性检验。

10 可复现性与产物索引

本轮 GPU 路径的训练函数墙钟时间累计为 5.40 小时，包含训练循环内验证与 checkpoint 开销，不含外部数据下载、四相机视频解码、最终评估和报告生成。完整性检查结果为 270/270；270 个 checkpoint 的 metadata 与 run manifest 均匹配。旧实验目录没有参与恢复或结果汇总。

内容	路径
实验定义与总览	runs/mixed_modality_damage_v1_3_0/study.json
结构化汇总	runs/mixed_modality_damage_v1_3_0/results.csv
完整 JSON 证据	runs/mixed_modality_damage_v1_3_0/results.json
交互式 HTML 报告	runs/mixed_modality_damage_v1_3_0/report.html
单次运行记录	runs/mixed_modality_damage_v1_3_0/<dataset>/<model> /<condition>/seed-*/

本报告由 Sync2Act 实验 schema v3、quality schema v2 的实测输出生成。

训练版本：Sync2Act v1.2.0；Git commit a5b4fbb1e7cb8c9704c3dbfc19a1ba563662068。

时间集成评估的代码指纹、环境与协议见 temporal_ensemble/summary.json。