

Sync2Act

Quality-Aware ACT

混合质量消融研究

完整数据集、六组消融、三个随机种子

实验规模

3个真实单任务数据集 × 6 个模型消融 × 5 个训练条件 × 3 个随机种子

完成状态

270 / 270 组成功完成

训练约束

完整 episode 与完整 frame；仅训练集损坏；验证集和测试集保持干净

核心指标

干净测试集 action MSE，以及相对同模型干净训练的 MSE 比值

生成日期

2026-09-13

结论预览

Oracle 模态质量对 temporal state shift 有稳定信号，但尚未形成跨损坏类型一致、幅度很大的收益。Quality-Full 相对 ACT-Lite 在 36 个“数据集 × 损坏条件 × seed”配对中有 22 个取得更低绝对 MSE；这说明方向值得继续验证，但不能据此声称闭环控制性能已提升。

1 研究目标与结论边界

本轮实验研究的不是“模型能否识别坏数据”，而是：当同一训练集中同时存在干净与损坏片段时，把按模态拆分的 Oracle quality 提供给 ACT-Lite，能否减弱坏示范对干净测试集动作预测的影响。Oracle quality 由已知的合成损坏参数直接计算，因此代表质量信息的理论上界，而不是部署时可直接获得的传感器输出。

所有结果均为**离线动作预测**。报告中的 MSE、MAE 和鲁棒性比值不能替代真实机器人或仿真器中的闭环成功率、回报和完成时间。因而本报告可以支持“训练数据损坏如何影响预测误差”的结论，但不能直接推出“机器人任务成功率提高”。

2 数据集与训练协议

三个数据集均为真实环境、单任务数据集；训练使用所有可用相机。数据按 episode 划分，避免同一 episode 的相邻帧同时进入训练与测试。

数据集	Episode	Frame	相机	State / Action	Train / Val / Test
XArm Lift Medium	800	20,000	1	4 / 4	640 / 80 / 80
Koch Pick Place 1 Lego	100	32,951	2	6 / 6	80 / 10 / 10
ALOHA Static Battery	49	29,400	4	14 / 14	41 / 4 / 4

表 1: 完整数据集统计。图像输入分别来自 1、2、4 个相机。

统一训练配置为 10 epochs、CUDA、随机种子 7/17/27、划分种子 7；ACT batch size 为 256，action segment length 为 16。图像最长边缩放至 64 像素。Normalization statistics 只从**干净训练集**计算并固定，避免损坏条件改变归一化标尺。

数据隔离规则

原始数据按 episode 划分后，仅 Training episodes 根据实验条件构造混合损坏；Validation episodes 与 Test episodes 始终保持干净。测试指标按 episode 内部计算轨迹量，再汇总，避免跨 Episode 跳变。

3 模态质量与混合质量构造

每个样本不再共享单一 quality，而是包含 image_quality、state_quality 与 action_label_quality。同时分别记录模态级 time_offset、missing_mask 和 provenance，使模型可以区分“观测不可信”和“动作标签不可信”。时间错位的质量随严重度连续衰减：

$$q_m = \exp\left(-\frac{|\Delta t_m|}{2\widetilde{\Delta t}}\right),$$

其中 Δt_m 为模态 m 的时间偏移， $\widetilde{\Delta t}$ 为数据集的中位帧间隔。因此 3 秒 shift 的 quality 低于 1 秒 shift，而非二者都使用同一个常数。

单一损坏条件按连续片段构造 50% 干净、50% 损坏样本；混合条件包含 25% 干净、25% temporal state shift、25% temporal action shift、25% action delay。连续片段比逐帧独立采样更接近真实传感器或同步故障。

训练条件	训练集构造	主要受影响质量
Clean	100% 干净	全部为 1
Temporal state shift 2	50% 干净 + 50% state 时间错位	state quality
Temporal action shift 2	50% 干净 + 50% action 时间错位	action-label quality
Action delay 2	50% 干净 + 50% action 延迟	action-label quality
Mixed three corruptions	四类各占 25%	按损坏模态分别变化

4 六组 Quality-Aware 消融

模型	Quality 输入	Quality 加权 loss	目的
ACT-Lite	否	否	无质量信息的基线
Quality-Input	是	否	测试质量作为条件输入是否有效
Quality-Weighted-Loss	否	是	测试降低低质量标签权重是否有效
Quality-Full	是	是	完整方法
Quality-Shuffled	打乱	是	负对照：破坏质量与样本的对应关系
Quality-Constant	常数	是	负对照：只有固定质量值

Quality-Shuffled 和 Quality-Constant 用于辨别收益究竟来自“真实的逐样本质量信号”，还是仅来自额外输入维度、损失缩放或随机训练差异。

5 指标

主要指标为干净测试集上的 action mean squared error:

$$\text{MSE} = \frac{1}{Nd} \sum_{i=1}^N \|\hat{a}_i - a_i\|_2^2.$$

由于三个数据集的动作单位和数值尺度不同，跨数据集汇总采用同一模型相对于干净训练条件的比值

$$R = \frac{\text{MSE}_{\text{corrupt train} \rightarrow \text{clean test}}}{\text{MSE}_{\text{clean train} \rightarrow \text{clean test}}}.$$

$R = 1$ 表示与干净训练持平； $R > 1$ 表示坏示范使预测变差； $R < 1$ 表示该训练条件下测试误差反而降低。比值先在每个数据集和 seed 内计算，再求均值。

6 总体结果




图 1: 三个数据集与三个 seeds 的平均相对 MSE。越低越好；虚线为干净训练基准。

模型	Clean	State shift	Action shift	Action delay	Mixed
ACT-Lite	1.000	1.242	1.004	0.992	1.009
Quality-Input	1.000	1.155	0.979	0.968	1.029
Weighted-Loss	1.000	1.240	0.981	0.981	1.071
Quality-Full	1.000	1.159	0.978	0.982	1.052
Shuffled	1.000	1.280	0.991	0.979	1.027
Constant	1.000	1.214	0.978	0.969	0.997

表 2: 平均 MSE 比值，列内最小值以绿色标出。

Temporal state shift 是唯一在所有模型上都明显恶化的损坏类型，ACT-Lite 平均上升 24.2%。Quality-Input 将该增幅降至 15.5%，Quality-Full 为 15.9%，说明显式质量输入对 state 错位最有希望。另一方面，Action shift、Action delay 和 Mixed 的均值大多接近 1；这些条件下约 1–3% 的变化不足以构成稳健的总体收益。

7 配对比较与数据集差异

在 36 个损坏配对（3 数据集 $\times$ 4 损坏条件 $\times$ 3 seeds）中，Quality-Full 相对 ACT-Lite 有 22 个取得更低绝对 MSE，按归一化鲁棒性比较则为 23/36。Quality-Full 相对 Shuffled 为 25/36，相对 Constant 为 21/36。这些负对照说明正确对应的 quality 确实携带信号，但优势尚不够一致。

数据集差异很大：Temporal state shift 对 Koch 与 ALOHA 的影响最强，而 XArm 变化较小；ALOHA 在 action shift 与 delay 下出现低于 1 的比值，但这种“改善”没有在 XArm 和 Koch 上复现，可能来自损坏带来的正则化、动作冗余或随机波动，不应直接解释为延迟有益。

比较	更低绝对 MSE	更好归一化比值	总配对数
Quality-Full vs ACT-Lite	22	23	36
Quality-Full vs Shuffled	25	–	36
Quality-Full vs Constant	21	–	36

数据集	模型	State shift	Action shift	Action delay	Mixed
XArm Lift	ACT-Lite	1.02	1.09	1.08	1.12
	Quality-Full	1.02	1.03	1.04	1.08
Koch Pick Place	ACT-Lite	1.36	1.02	1.01	1.01
	Quality-Full	1.22	0.96	0.96	1.05
ALOHA Battery	ACT-Lite	1.34	0.90	0.88	0.90
	Quality-Full	1.25	0.95	0.95	1.03

表 3: 按数据集汇总的 MSE 比值。数值为报告中跨三个 seeds 的均值，保留两位小数。

8 结论、限制与下一步

主要结论

1. 数据损坏对训练的影响高度依赖损坏模态和数据集；Temporal state shift是当前最稳定的负面因素。
2. Oracle 模态质量包含可利用信息。Quality-Input 和 Quality-Full 明显缓解了平均 state-shift 退化，且 Quality-Full 多数配对优于打乱质量的负对照。
3. Quality-Full 并未在所有损坏条件和数据集上一致胜出。因此当前证据支持“继续研究”，不支持“已解决坏示范训练问题”。

本研究仍有四项关键限制：（1）仅测试三个 seeds；（2）评价为离线动作误差，没有闭环 rollout；（3）跨数据集动作单位不同，绝对 MSE 不可直接横向比较；（4）quality 来自合成损坏真值，实际部署时未知。图像缩放到较低分辨率也可能削弱视觉质量差异。

建议下一阶段按以下顺序推进：

1. 先围绕 temporal state shift 增加严重度梯度与随机种子，检验收益是否稳定且随 quality 单调变化；
2. 将质量输入、加权函数及其校准误差进一步拆开，报告 bootstrap 置信区间和配对显著性；
3. 使用已知 corruption provenance 训练自动质量估计器，再用其预测质量替代 Oracle quality，衡量从上界到可部署方案的性能损失；
4. 最后在仿真或真实机器人上进行闭环 rollout，报告成功率与安全失败类型，再决定是否扩展至完整损坏矩阵。

9 可复现性与产物索引

本轮累计 GPU 训练时间为 6.73 小时，结果完整性检查为 270/270。所有 checkpoint、逐帧预测、逐 episode 指标与 run metadata 均保存在实验目录中。

内容	路径
实验定义与总览	<code>runs/quality_ablation_v1_2_0/study.json</code>
结构化汇总	<code>runs/quality_ablation_v1_2_0/results.csv</code>
交互式 HTML 报告	<code>runs/quality_ablation_v1_2_0/report.html</code>
单次运行记录	<code>runs/quality_ablation_v1_2_0/<dataset>/<model>/<condition>/seed-*/</code>