

Sync2Act

数据质量与策略鲁棒性

从受损示范学习，到受损观测下的动作预测

v1_4_0 / 2026-10-07

研究问题：已知数据质量信息，应如何进入模仿学习系统？本研究在同一组机器人任务和固定模型上，连接训练数据损坏、测试观测损坏和动作块时间集成三类实验，区分学习阶段与预测阶段的收益。

实验维度	规模
训练与消融	3数据集 × 6 模型 × 5 条件 × 3 seeds = 270
测试鲁棒性	4,158 次评估，包含 270 个干净基线核对
时间集成	270 组配对；固定 decay=0.7

主要发现。正确动作标签质量加权能显著缓解训练示范损坏：动作标签损坏时，Q-Full 与 ACT-Lite 的平均训练退化比分别为 0.977 和 2.432；综合损坏时为 1.144 和 1.535。但在同样采用综合损坏训练后，Q-Full 在 ALOHA 中等状态损坏测试中的配对 MSE 比 ACT-Lite 高约 36.1%，Koch 和 xArm 则分别低约 3.0% 和 2.1%。训练阶段的收益不会自动转化为受损输入下的优势。

固定 decay=0.7 的时间集成未降低总体实际 MSE：270 组逐运行变化百分比的均值为 +21.20%。本文同时报告绝对误差与四类配对比值，避免将分母变化误解为性能改善。

本文整合既有训练与评估结果，未重新训练。所有结果是离线动作预测，不代表真实机器人闭环成功率。

目录

1	研究问题与统一实验设计	3
2	模型消融与受损训练条件	4
3	故障注入与评估流程	5
4	指标、配对关系与不确定性	6
5	从受损示范中学习：干净测试结果	7
6	固定模型面对受损测试观测	10
7	质量信息的作用与跨条件比较	13
8	预测方式：因果时间集成	15
9	联合结论、局限与后续验证	17
10	审计与可复现性	18
A	完整中等强度测试矩阵：ALOHA	20
B	完整中等强度测试矩阵：Koch	21
C	完整中等强度测试矩阵：xArm	22

阅读顺序：第 1–4 节统一定义实验与指标；第 5 节研究训练示范质量；第 6–7 节检验测试输入及质量信息；第 8 节评估预测方式；第 9–10 节给出联合结论、局限和复现信息。附录列出完整受损测试矩阵。

1 研究问题与统一实验设计

数据损坏可能发生在学习阶段，也可能发生在模型使用阶段。前者影响监督信号与学到的策略，后者直接改变预测时可用的观测。研究分别检验：质量输入和标签加权是否改善受损示范学习；固定模型面对图像/状态故障时是否稳健；时间集成是否降低同一轨迹上的预测误差。

训练	测试	本报告中的位置
干净	干净	历史基线的重新核对
受损	干净	历史基线的重新核对
干净	受损	新增测试鲁棒性结果
受损	受损	新增跨条件结果

数据集	Ep.	Frames	Cam.	S / A	Train / Val / Test	测试帧
ALOHA	49	29,400	4	14 / 14	41 / 4 / 4	2,400
Koch	100	32,951	2	6 / 6	80 / 10 / 10	3,342
xArm	800	20,000	1	4 / 4	640 / 80 / 80	2,000

ALOHA为静态电池操作，Koch为单块Lego拾放，xArm为抬升任务；三个数据集均通过单任务检查。使用完整 episodes、完整 frames 和全部同步相机，先按 episode 固定划分，再分别构造训练损坏与测试观测副本，避免相邻帧跨分区泄漏。“干净”表示未追加合成故障，并不保证原始记录完全没有噪声。固定划分种子为7，训练种子为7、17、27，图像最长边64像素，10 epochs、CUDA、batch size 256、动作 horizon 8。每个数据集仅从干净训练 episodes 计算一次归一化，并在其90组模型/条件/种子组合中固定；测试从 checkpoint 恢复这些统计量。验证集保持干净，测试故障不改变划分或训练统计量。

2 模型消融与受损训练条件

ACT-Lite是轻量动作块预测模型，省略原始 ACT 的 CVAE 路径。Q-Full 等质量模型复用其骨干，按相机和状态分别处理观测质量。BC-MLP 虽由软件支持，但没有进入这 270 个历史 checkpoint 的实验矩阵。

模型	训练时质量输入	标签加权
ACT-Lite	无	否
Q-Input	真实合成元数据	否
Q-Weighted	无	是
Q-Full	真实合成元数据	是
Q-Shuffled	打乱的质量元数据	是，使用打乱值
Q-Constant	恒定为正常	是，使用常数值

训练片段的故障构成如下，测试观测使用下一节的独立配方。C/I/S/A/M 是后续表格使用的训练条件缩写。

条件	训练片段构成
C	100% 干净
I	50% 干净；40% 图像延迟 2 帧；10% 图像缺失
S	50% 干净；40% 状态延迟 2 帧；10% 状态缺失
A	50% 干净；40% 动作延迟 2 帧；10% 动作标签缺失
M	20% 干净；图像/状态延迟各 20%；动作延迟 25%；图像/状态/动作缺失各 5%

本轮 Oracle 测试向六种训练变体提供相同的真实观测质量元数据，包括训练时使用 shuffled/constant 的模型。训练消融与推理时的元数据干预是两种不同的对照。动作标签质量不参与测试指标加权。

表中的 Q- 是 Quality- 的缩写，Q-Weighted 对应 Quality-Weighted-Loss。Q-Shuffled 打破逐样本质量对应关系，Q-Constant 将质量标为正常。缺失图像/状态不删除整个训练样本；缺失动作涉及标签可靠性，只有启用标签质量加权的损失会降低或移除其监督贡献。

3 故障注入与评估流程

训练故障。每条 episode 按连续 16 帧分段，按权重互斥分配一个故障类别，片段不重复计入多个比例。训练移位为 2 帧，越界标记缺失；对应输入/标签与质量置零，并记录 mask 和 provenance。实际片段比例与目标最大偏差约 0.03 个百分点；按帧计，单模态条件最大约 0.35 个百分点，综合条件约 0.83，源于 episode 尾部不足 16 帧的片段。

每条测试轨迹划分为连续的 16 帧片段，按确定性随机种子互斥分配故障类型。延迟读取同一 episode 的过去观测，缺失输入置零。边界不足以读取过去帧时，使用缺失标记；不删帧、不跨 episode，也不读取未来帧。

$$\tilde{o}_t = o_{t-\Delta}, \quad \Delta > 0; \quad \tilde{a}_t^{\text{target}} = a_t.$$

强度	延迟帧数	单模态：延迟 / 缺失	混合：延迟 / 缺失
轻	1	0.20 / 0.05	0.30 / 0.10
中	2	0.40 / 0.10	0.60 / 0.20
重	4	0.60 / 0.20	0.70 / 0.30

单模态条件分别损坏图像或状态。混合条件把延迟份额、缺失份额各自平分给图像与状态；例如中等混合测试为 20% 干净、30% 图像延迟、30% 状态延迟、10% 图像缺失、10% 状态缺失。余下份额为干净片段。

这些比例按片段分配，并非逐帧独立丢失概率。episode 尾部短片段会使实际受损帧比例与目标略有不同；逐评估清单保存实际比例和毫秒偏移。三个测试损坏种子为 107、117、127，与训练种子独立。相同数据集、条件和种子下，所有模型使用同一组受损输入。

实验组	构成	数量
干净基线	270	270
中等 Oracle	$270 \times 3 \times 3$	2,430
未知元数据	$90 \times 3 \times 3$	810
轻 / 重强度	$36 \times 2 \times 3 \times 3$	648
总计		4,158

未知元数据组覆盖 Q-Input、Q-Full 的全部训练条件。强度扩展覆盖 ACT-Lite、Q-Full 的 C 和 M 训练条件。轻/中/重同时改变延迟和受损比例，因此不应解释为单变量敏感性实验。

4 指标、配对关系与不确定性

默认评估取动作块首步，反归一化到原动作单位；MSE对全部测试帧和动作维度等权平均，MAE 同样计算。测试指标不按质量降权，动作标签始终固定。不同机器人的动作尺度不同，不跨数据集合并原始 MSE。

$$E = \frac{1}{ND} \sum_{t=1}^N \sum_{j=1}^D (\hat{a}_{t,j} - a_{t,j})^2.$$

$$\begin{aligned} R_{\text{train}} &= \frac{E_{\text{damaged train, clean test}}}{E_{\text{clean train, clean test}}}, \\ R_{\text{test}} &= \frac{E_{\text{same checkpoint, damaged test}}}{E_{\text{same checkpoint, clean test}}}, \\ P &= \frac{E_{\text{Q-Full}}}{E_{\text{ACT-Lite}}}, \quad U = \frac{E_{\text{unknown metadata}}}{E_{\text{Oracle metadata}}}. \end{aligned}$$

R_{train} 固定数据集、模型与训练种子，衡量损坏训练的影响； R_{test} 固定 checkpoint，衡量损坏测试的影响。 P 固定训练/测试条件及种子，小于 1 才表示 Q-Full 绝对误差更低； U 仅改变推理质量元数据，大于 1 表示隐去质量信息使误差更高。各比值先逐配对计算再平均，分母为零时未定义。

训练损坏总体曲线平均 3 数据集 $\times$ 3 训练 seeds 的 9 个比值。受损测试则在每个训练种子内先平均 3 个独立损坏 seeds (107、117、127)，再平均 3 个训练 seeds；报告训练种子间样本标准差，并在 CSV 中保留训练种子内损坏标准差的均值。3 $\times$ 3 配对不是 9 次独立训练，不给出显著性或置信区间结论。

$$\bar{R}_s = \frac{1}{3} \sum_r R_{s,r}, \quad \bar{R} = \frac{1}{3} \sum_s \bar{R}_s, \quad s_{\text{train}} = \sqrt{\frac{\sum_s (\bar{R}_s - \bar{R})^2}{2}}.$$

退化倍率更低不一定意味着绝对误差更低，尤其不能跨训练条件或跨评估方式忽略分母变化。训练结果章节的 R 指训练退化比，受损测试章节的 R 指同 checkpoint 测试退化比。

5 从受损示范中学习：干净测试结果

首先保持测试观测干净，隔离训练示范质量的影响。六组模型采用相同划分、预处理和训练预算，因此可通过质量输入与标签加权的消融判断收益来源。下图与表使用训练退化比；其中最低值只表示观察到的均值最小。




图 1: 三个数据集与三个 seeds 的平均相对 MSE。越低越好；虚线为干净训练基准。

模型	Image damaged	State damaged	Action damaged	Mixed
ACT-Lite	0.999	1.388	2.432	1.535
Quality-Input	0.995	1.234	2.394	2.007
Weighted-Loss	1.000	1.374	0.992	1.163
Quality-Full	0.996	1.238	0.977	1.144
Shuffled	1.004	1.449	2.463	1.538
Constant	0.994	1.303	2.401	1.500

表 1: 平均 MSE 比值。绿色仅标示列内最小值，不代表统计显著性。

5.1 故障模态揭示的收益来源

5.1.1 Action 标签损坏：加权 loss 是关键

ACT-Lite 在 action-damaged 条件下平均退化到 $2.432\times$ ，Quality-Input 仍为 $2.394\times$ 。Quality-Input 只接收观测质量，并不知道动作标签质量；只要错误标签继续以普通权重进入 loss，监督信号仍会把模型拉向错误目标。

Quality-Weighted-Loss 将比值降至 $0.992\times$ ，Quality-Full 为 $0.977\times$ 。Shuffled 与 Constant 分别退化到 $2.463\times$ 和 $2.401\times$ ，这些对照支持正确对齐的逐样本 **action-label quality** 的重要性，不能仅将收益归因于额外输入维度、随机降权或模型容量。

模型	XArm MSE	Koch MSE	ALOHA MSE
ACT-Lite	0.406790	21.5804	0.0009031
Quality-Input	0.405661	21.4460	0.0009163
Weighted-Loss	0.388007	7.3369	0.0002718
Quality-Full	0.387742	7.3168	0.0002662
Shuffled	0.407930	21.8305	0.0009603
Constant	0.406804	21.5116	0.0009184

表 2: Mixed action damaged 的三-seed 平均绝对 MSE。不同数据集之间不可横向比较数值大小。

5.1.2 State 观测损坏：quality 输入有帮助但不完全

State damaged 使 ACT-Lite 平均退化到 $1.388\times$ 。Quality-Input 和 Quality-Full 分别为 $1.234\times$ 与 $1.238\times$ ，优于不使用 observation quality 的 Weighted-Loss ($1.374\times$)。然而两者仍明显高于 1，说明 quality 元数据只能帮助模型识别不可靠 state，并不能恢复被错位或置零的信息。

5.1.3 Image 观测损坏：当前离线指标不敏感

所有模型在 image-damaged 条件下都约为 $1.0\times$ 。正确 image quality、打乱 quality 和恒定 quality 之间没有稳定差距。这个结果只能说明在当前 64 像素输入、所选任务与离线 action MSE 下，40% 两帧图像错位加 10% 全相机缺失没有形成可辨别的平均退化；不能据此断言真实闭环控制对视觉故障不敏感。

5.1.4 综合损坏：主要收益来自处理坏 action 标签

综合条件下，ACT-Lite 为 $1.535\times$ ，Quality-Input 反而达到 $2.007\times$ ；Weighted-Loss 与 Quality-Full 分别降至 $1.163\times$ 和 $1.144\times$ 。Full 仅比 Weighted-Loss 略好，说明主要收益仍来自 action-label weighting，observation quality 的额外贡献较小且随 seed 波动。

5.2 任务差异与模型配对

总体均值不能替代逐任务比较。下面同时保留各模型自身基线归一化后的结果，以及同条件绝对误差的胜出次数；两者回答的问题不同。

数据集	模型	Image	State	Action	Mixed
XArm Lift	ACT-Lite	1.000	1.024	1.073	1.059
	Quality-Full	1.000	1.013	1.024	1.029
Koch Pick Place	ACT-Lite	1.000	1.467	2.958	1.774
	Quality-Full	1.017	1.270	0.964	1.123
ALOHA Battery	ACT-Lite	0.997	1.674	3.265	1.773
	Quality-Full	0.973	1.430	0.942	1.279

表 3: 按数据集汇总的三-seed平均 MSE 比值。

XArm 对本轮损坏整体较不敏感；Koch 与 ALOHA 的 state/action 损坏更明显。因此不能只用一个数据集判断质量机制。Quality-Full 相对 ACT-Lite 在 36 个损坏配对中有 31 个获得更低绝对 MSE，按各自 clean 基线归一化后也是 31/36。相对 Shuffled 为 32/36 个更低绝对 MSE，相对 Constant 为 29/36。

比较	Full 更低绝对 MSE	Full 更低相对比值	总配对数
Quality-Full vs ACT-Lite	31	31	36
Quality-Full vs Shuffled	32	31	36
Quality-Full vs Constant	29	29	36
Quality-Full vs Quality-Input	29	28	36
Quality-Full vs Weighted-Loss	23	24	36

6 固定模型面对受损测试观测

训练损坏实验说明模型能否从不可靠示范中学习，但不能回答部署输入受损时是否可靠。下面保持同一 checkpoint、动作标签与归一化，只改变留出轨迹的观测；先检查干净训练模型，再检查见过综合损坏的模型。

6.1 干净训练模型的敏感性

首先比较 C 训练条件、中等损坏、Oracle 元数据。每一行对应 3 个训练种子与 3 个损坏种子的配对评估。MSE 是原动作单位下的平均误差，R 的分母是同一 checkpoint 的干净测试误差。

数据集	模型	测试	平均 MSE	$\bar{R} \pm s_{\text{train}}$
ALOHA	ACT-Lite	图像	3.345e-04	1.158 $\pm$ 0.005
ALOHA	ACT-Lite	状态	7.563e-03	26.397 $\pm$ 1.934
ALOHA	ACT-Lite	混合	7.551e-03	26.355 $\pm$ 1.929
ALOHA	Q-Full	图像	3.349e-04	1.178 $\pm$ 0.124
ALOHA	Q-Full	状态	0.0152	53.832 $\pm$ 6.362
ALOHA	Q-Full	混合	0.0131	46.527 $\pm$ 5.331
Koch	ACT-Lite	图像	7.7389	1.054 $\pm$ 0.039
Koch	ACT-Lite	状态	205.7562	28.149 $\pm$ 2.135
Koch	ACT-Lite	混合	204.0508	27.914 $\pm$ 2.071
Koch	Q-Full	图像	8.1117	1.069 $\pm$ 0.073
Koch	Q-Full	状态	351.1573	46.384 $\pm$ 4.630
Koch	Q-Full	混合	302.6846	39.968 $\pm$ 3.418
xArm	ACT-Lite	图像	0.3791	1.000 $\pm$ 0.000
xArm	ACT-Lite	状态	0.4583	1.209 $\pm$ 0.028
xArm	ACT-Lite	混合	0.4513	1.191 $\pm$ 0.027
xArm	Q-Full	图像	0.3786	1.000 $\pm$ 0.000
xArm	Q-Full	状态	0.4178	1.103 $\pm$ 0.050
xArm	Q-Full	混合	0.4124	1.089 $\pm$ 0.041

图像受损对三个数据集的影响显著小于状态受损，但并非完全无影响。例如 ALOHA 的 ACT-Lite 图像条件平均 R 为 1.158；状态条件达到 26.397。xArm 的相应比值为 1.000 和 1.209，说明不同任务对同一故障配方的敏感性差异很大。

干净训练的 Q-Full 在 ALOHA 与 Koch 的状态/混合损坏下没有显示优势；xArm 的趋势不同。不能用单一数据集或单个 seed 推断质量机制普遍有效。

6.2 综合损坏训练后的测试鲁棒性

进一步固定为 M 训练条件、中等测试损坏和 Oracle 元数据。与干净训练模型的绝对 MSE 对照，可观察历史损坏训练模型在同一测试故障下的表现；各组 R 的分母仍是各自 checkpoint 的干净测试误差。


数据集	模型	测试	平均 MSE	$\bar{R} \pm s_{\text{train}}$
ALOHA	ACT-Lite	图像	4.986e-04	1.002 ± 0.009
ALOHA	ACT-Lite	状态	3.945e-03	7.937 ± 0.385
ALOHA	ACT-Lite	混合	3.907e-03	7.860 ± 0.399
ALOHA	Q-Full	图像	3.592e-04	0.994 ± 0.019
ALOHA	Q-Full	状态	5.325e-03	15.162 ± 5.258
ALOHA	Q-Full	混合	5.279e-03	15.031 ± 5.219
Koch	ACT-Lite	图像	12.8291	0.987 ± 0.003
Koch	ACT-Lite	状态	149.8475	11.548 ± 0.498
Koch	ACT-Lite	混合	147.8348	11.393 ± 0.478
Koch	Q-Full	图像	8.5624	1.004 ± 0.008
Koch	Q-Full	状态	145.2861	17.080 ± 1.012
Koch	Q-Full	混合	143.9248	16.921 ± 1.021
xArm	ACT-Lite	图像	0.4012	1.000 ± 0.001
xArm	ACT-Lite	状态	0.4122	1.027 ± 0.003
xArm	ACT-Lite	混合	0.4110	1.024 ± 0.003
xArm	Q-Full	图像	0.3882	0.997 ± 0.002
xArm	Q-Full	状态	0.4037	1.037 ± 0.003
xArm	Q-Full	混合	0.4011	1.030 ± 0.002

$P = \text{Q-Full} / \text{ACT-Lite}$	图像	状态	混合
ALOHA	0.723	1.361	1.362
Koch	0.669	0.970	0.974
xArm	0.968	0.979	0.976

Q-Full 在 ALOHA 的状态和混合测试中分别比 ACT-Lite 高约 36.1% 和 36.2% 的配对 MSE；Koch 与 xArm 的比值略低于 1。这里报告的是观察到的均值，不意味着小幅差异具有统计显著性。

6.3 故障强度与任务敏感性

仅展示 ACT-Lite 与 Q-Full、C 与 M 训练条件、Oracle 元数据。纵轴为同一 checkpoint 的 MSE 退化比 R，使用对数刻度。每个点先平均损坏种子，再平均训练种子。接近基线的面板至少覆盖 0.9–1.1；各面板纵轴范围不同。



蓝色：ACT-Lite；橙色：Q-Full。虚线：C 训练；实线：M 训练。图中展示均值，未绘制置信区间。

状态/混合故障随强度上升通常呈更大退化，ALOHA 与 Koch 最为明显。R 的大小不能代替跨模型绝对误差比较；对模型优劣应同时查看第 6 节的配对 P。

7 质量信息的作用与跨条件比较

7.1 同一受损输入：Oracle 与 Unknown

Oracle 使用合成故障产生的质量分数、缺失标记和时间偏移；Unknown 将观测质量设为 1、缺失标记和时间偏移设为 0。两者使用完全相同的受损图像/状态与同一 checkpoint。Unknown 不会修复观测。下表展示 C 与 M 训练条件，其他训练条件见机器可读结果。

数据集	模型	训练	图像	状态	混合
ALOHA	Q-Input	C	0.877	0.506	0.582
ALOHA	Q-Input	M	1.203	1.577	1.607
ALOHA	Q-Full	C	0.879	0.507	0.583
ALOHA	Q-Full	M	1.144	1.507	1.522
Koch	Q-Input	C	0.943	0.579	0.665
Koch	Q-Input	M	1.254	1.447	1.467
Koch	Q-Full	C	0.942	0.580	0.665
Koch	Q-Full	M	0.996	1.389	1.386
xArm	Q-Input	C	1.000	1.113	1.110
xArm	Q-Input	M	1.014	1.050	1.055
xArm	Q-Full	C	1.000	1.119	1.115
xArm	Q-Full	M	1.004	1.099	1.096

表内为 $U = \text{MSE}_{\text{unknown}}/\text{MSE}_{\text{Oracle}}$ 的配对均值。对于 M 训练的 Q-Full，状态损坏下的 U 在 ALOHA、Koch 和 xArm 分别约为 1.507、1.389、1.099，说明隐去正确质量信息会提高这些条件下的平均误差。

但 C 训练的 Q-Full 在 ALOHA/Koch 状态损坏下的 U 约为 0.507/0.580，即 Unknown 反而更好。一个可能解释是，干净训练没有让模型学会正确处理低质量输入及其元数据；这只是待验证假设，不能由本实验单独证明。

Oracle 在这里表示已知合成故障来源，并不表示质量分数经过概率校准，也不是模型性能的理论上界。部署时如何自动检测质量，未在本轮实验中解决。

7.2 为何干净测试的优势未必延续

为直接连接上述两组结果，下面固定综合损坏训练 (M)、首步预测和 Oracle 测试质量信息，比较同一批模型在干净与中等受损观测上的表现。表中为逐种子配对的 Q-Full / ACT-Lite MSE 百分比变化，负数代表 Q-Full 更好。

数据集	干净	图像损坏	状态损坏	混合损坏
ALOHA	-26.9%	-27.7%	+36.1%	+36.2%
Koch	-34.2%	-33.1%	-3.0%	-2.6%
xArm	-3.0%	-3.2%	-2.1%	-2.4%

ALOHA 的优势在状态/混合损坏下反转；Koch 的优势大幅缩小，xArm 仍为小幅差异。正确质量信息能帮助 Q-Full，并不保证它超越 ACT-Lite；这些均值也未经过显著性检验。下表进一步确认，ACT-Lite 自身同样会随状态损坏退化。

ACT-Lite MSE	干净	图像损坏	状态损坏	混合损坏
ALOHA	4.979e-04	4.986e-04	3.945e-03	3.907e-03
Koch	12.9916	12.8291	149.8475	147.8348
xArm	0.4014	0.4012	0.4122	0.4110

状态损坏后的同 checkpoint 配对退化倍率依次为 7.94、11.55、1.03。损坏训练不是对测试故障的免疫。以上结果支持区分训练时处理坏标签与预测时处理坏观测；对于 ALOHA 反转的具体机制，仍需单独消融验证。

8 预测方式：因果时间集成

除了数据质量，动作块如何转化为逐帧预测也可能影响指标。本节在干净测试观测上比较首步预测与时间集成，模型权重完全相同；因此这里测量的是预测方式的影响，不能据此推断集成在受损观测上的表现。

两种评估方式使用同一组 270 个 checkpoint、测试 episodes 和归一化统计量；decay=0.7 在评估前固定。只融合起点不晚于当前时刻的预测，并在每条 episode 边界重置历史。第一步预测一致性核对为 270/270 通过。两种评估方式采用相同的归一化规则：先在每个数据集、模型、seed 内，用该条件的测试 MSE 除以同一模型同一 seed 的干净训练测试 MSE，再平均 9 个比值。时间集成曲线的分子和分母均使用集成后的 MSE；两种方式的横轴、六模型配色和纵轴范围一致。

$$R_{\text{ens}} = \frac{\text{MSE}_{\text{damaged train, ens}}}{\text{MSE}_{\text{clean train, ens}}}.$$




图 2: 时间集成后的平均相对 MSE。每点平均 3 数据集与 3 seeds 的 9 个比值；虚线为时间集成后的干净训练基准。

模型	Image	State	Action	Mixed
ACT-Lite	1.0012	1.2514	2.1177	1.4070
Quality-Input	1.0015	1.1328	2.0711	1.6831
Weighted-Loss	1.0018	1.2465	1.0089	1.1215
Quality-Full	1.0022	1.1360	1.0002	1.0970
Shuffled	1.0091	1.2636	2.1074	1.3787
Constant	0.9999	1.1959	2.0747	1.3916

表 4: 时间集成的平均 MSE 比值，衡量相对于干净训练的退化程度。集成前后的实际误差变化见配对比较。

8.1 退化比下降与实际误差的区别

下表逐运行计算 $100 \times (\text{集成后 MSE} / \text{未集成 MSE} - 1)$ ，再对 3 数据集 $\times$ 3 seeds 取平均。负数表示 MSE 降低，正数表示 MSE 增加；不跨机器人直接平均原始 MSE。

模型	Clean	Image	State	Action	Mixed
ACT-Lite	+27.37%	+27.72%	+15.23%	+11.47%	+16.74%
Quality-Input	+27.65%	+28.58%	+17.27%	+11.29%	+8.59%
Weighted-Loss	+27.32%	+27.68%	+15.87%	+29.56%	+22.52%
Quality-Full	+27.67%	+28.46%	+17.22%	+31.16%	+22.64%
Shuffled	+27.51%	+28.10%	+11.55%	+10.29%	+14.60%
Constant	+27.58%	+28.29%	+17.16%	+11.10%	+17.89%

表 5: 实际 MSE 的平均配对变化百分比。每格 9 次运行；正数表示误差增加。

下表在同一数据集、同一模型内对五个训练条件和三个 seeds 的 15 次运行取平均。MSE 差值 = 集成后均值 - 未集成均值；变化 (%) = $100 \times (\text{集成后均值} / \text{未集成均值} - 1)$ 。此处的均值之比不同于上表逐运行百分比的均值。

数据集	模型	未集成 MSE	集成后 MSE	MSE 差值	变化
XArm	ACT-Lite	0.39085	0.39331	+0.002467	+0.63%
XArm	Quality-Input	0.39089	0.39226	+0.001367	+0.35%
XArm	Weighted-Loss	0.38469	0.38938	+0.004692	+1.22%
XArm	Quality-Full	0.38362	0.38759	+0.003975	+1.04%
XArm	Shuffled	0.39163	0.39363	+0.001998	+0.51%
XArm	Constant	0.39087	0.39338	+0.002507	+0.64%
Koch	ACT-Lite	11.986	16.958	+4.972	+41.48%
Koch	Quality-Input	13.35	18.178	+4.828	+36.16%
Koch	Weighted-Loss	8.224	12.919	+4.695	+57.08%
Koch	Quality-Full	8.1593	12.941	+4.781	+58.60%
Koch	Shuffled	12.532	17.4	+4.867	+38.84%
Koch	Constant	11.936	16.915	+4.978	+41.71%
ALOHA	ACT-Lite	0.0004896	0.00053513	+4.553e-05	+9.30%
ALOHA	Quality-Input	0.00050224	0.00054808	+4.584e-05	+9.13%
ALOHA	Weighted-Loss	0.00033546	0.00037695	+4.149e-05	+12.37%
ALOHA	Quality-Full	0.00031741	0.00036239	+4.498e-05	+14.17%
ALOHA	Shuffled	0.00050376	0.00054189	+3.813e-05	+7.57%
ALOHA	Constant	0.00048196	0.00053488	+5.292e-05	+10.98%

表 6: 同一数据集内的实际 MSE 对照。每行平均五条件、三 seeds，共 15 次运行。

270 组逐运行 MSE 相对变化的平均值为 +21.20%。相对退化曲线下降不等于实际 MSE 下降：时间集成也会改变作为分母的干净训练基线。判断是否更准确，应同时查看未集成与集成后的实际 MSE。结果仅限离线动作预测。完整条件对照见 HTML 可展开表格及 `temporal_ensemble/mse_by_dataset_model_condition.csv`。

复现: `python tools/evaluate_temporal_study.py --device cuda --decay 0.7 --report-only`。

9 联合结论、局限与后续验证

标签质量加权是受损示范学习的主要收益来源。动作标签损坏时 Q-Full 的训练退化比为 0.977，而 ACT-Lite 为 2.432；综合损坏时为 1.144 与 1.535。Shuffled/Constant 对照支持逐样本质量对齐的重要性。Q-Full 的综合损坏平均退化比最低，但相对 Q-Weighted 的额外优势较小。

状态质量与测试鲁棒性必须分别检验。质量输入能部分缓解训练状态损坏，却不能恢复缺失信息；测试状态损坏仍可明显放大误差。综合损坏训练下，Q-Full 的 ALOHA 状态测试配对 MSE 高约 36.1%，而 Koch/xArm 仅有小幅优势。隐去正确质量信息会使该 Q-Full 的状态测试误差分别增加约 50.7%、38.9%、9.9%，说明信息有用不等于模型必然胜出。

视觉与时间集成结论有明确边界。当前 64 像素、所选故障与离线 MSE 对图像损坏的敏感性有限；这不是视觉故障没有闭环风险的证明。固定 $\text{decay}=0.7$ 的时间集成使 270 个逐运行 MSE 变化平均为 +21.20%，没有显示总体实际误差收益；尚未在受损测试观测上评估集成。

只有三个任务与三个训练种子；质量分数是已知合成故障的启发式映射，不是校准概率或理论性能上界。未评估自动质量估计、真实在线延迟、动作执行反馈与闭环安全，也未按新训练协议重训。

后续验证：先通过 ALOHA 机制消融区分质量输入、标签加权与故障训练分布；利用 provenance 学习 image/state/action-label 质量估计器并检查校准，再用预测质量替换 Oracle；提高视觉分辨率、故障强度与持续时间；在仿真或实机检验成功率、安全失败和恢复行为；若闭环趋势成立，再扩大 seeds、任务与强度并给出配对置信区间或显著性检验。

10 审计与可复现性

270个干净基线全部通过历史目标值、预测值和 MSE 核对，最大逐帧预测绝对差异为 0。所有测试动作标签、时间戳、episode 顺序和训练归一化均固定。运行清单记录 checkpoint 哈希、代码哈希、测试张量哈希、测试划分及损坏配置，输出文件使用 SHA-256 校验。

执行环境	记录值
Python	3.13.13
PyTorch	2.14.0+cu130
NumPy	2.5.2
GPU	NVIDIA GeForce RTX 5060 Laptop GPU
批量评估耗时	21.07 min

耗时仅表示本机离线批量流程，不是实时控制延迟。新增软件界面支持干净/受损配对评估、摄像头选择、随机种子、Oracle/Unknown 切换、后台执行与取消，以及带配置的 HTML/JSON 导出。实现验证记录为 120 项测试通过。

```
python tools/evaluate_test_corruption_study.py --device cuda
python tools/evaluate_test_corruption_study.py --report-only
python tools/build_test_corruption_latex_report.py
```

训练侧完整性审计为 270/270：保留各 checkpoint、预测 CSV、逐 episode 指标与 manifest，schema、signature、metadata 均匹配，没有缺失或重复组合，每个数据集只有一套归一化。训练函数墙钟累计 5.40 小时，包含循环内验证和 checkpoint，不含下载、四相机解码、最终评估与报告生成；旧实验目录未用于恢复或汇总。该训练耗时与表中的测试批量耗时不是同一种测量。

10.1 产物索引与来源记录

内容	路径
实验定义与总览	runs/mixed_modality_damage_v1_3_0/study.json
结构化汇总	runs/mixed_modality_damage_v1_3_0/results.csv
完整 JSON 证据	runs/mixed_modality_damage_v1_3_0/results.json
交互式 HTML 报告	runs/mixed_modality_damage_v1_3_0/report.html
单次运行记录	runs/mixed_modality_damage_v1_3_0/<dataset>/<model> /<condition>/seed-*/

本报告由 Sync2Act 实验 schema v3、quality schema v2 的实测输出生成。

训练版本：Sync2Act v1.2.0；Git commit a5b4fbb1e7cb8c9704c3dbfc19a1ba563662068。

时间集成评估的代码指纹、环境与协议见 temporal_ensemble/summary.json。

上述路径对应训练与干净测试。受损测试目录为 runs/test_time_corruption_v1/，保留 results.csv、aggregate.csv、per_training_seed.csv、quality_vs_act.csv、metadata_comparison.csv、summary.json 以及逐运行故障清单、预测与 episode 指标。逐运行指标、两级汇总及模型/元数据配对结果分别保存；受损与未受损片段的误差也在原始输出中。

时间集成目录 runs/mixed_modality_damage_v1_3_0/temporal_ensemble/ 保存配对预测、完整动作块、代码指纹、环境与配置。relative_mse_by_model_condition.csv 支持总体曲线，mse_by_dataset_model_condition.csv 支持完整条件对照，mse_per_run.csv 保存逐运行误差。

本文基于日期为 2026-10-02 的 v1_3_0 报告及 2026-10-07 的完整测试评估，统一重写研究叙述。源码包保留原始中英文来源和 SHA-256，可核对所有历史结果；当前图表与表格均内嵌于 LaTeX，无外部图片依赖。报告版本 v1_4_0 不代表发布了同版本软件安装包。

```
python tools/build_test_corruption_latex_report.py
使用 XeLaTeX 分别编译两份源码两次。
```

A 完整中等强度测试矩阵：ALOHA

六组模型、五种训练条件的 Oracle 测试。各单元格为 $\bar{R} \pm s_{\text{train}}$ ，每格由 3 个训练种子和 3 个损坏种子组成。C/I/S/A/M 的含义见第 2 节。

模型	训练	图像	状态	混合
ACT-Lite	C	1.158 ± 0.005	26.397 ± 1.934	26.355 ± 1.929
ACT-Lite	I	1.002 ± 0.008	26.536 ± 0.203	26.343 ± 0.206
ACT-Lite	S	5.346 ± 6.131	5.113 ± 2.128	8.766 ± 4.539
ACT-Lite	A	1.037 ± 0.024	9.483 ± 2.788	9.445 ± 2.801
ACT-Lite	M	1.002 ± 0.009	7.937 ± 0.385	7.860 ± 0.399
Q-Input	C	1.179 ± 0.123	53.849 ± 6.562	46.548 ± 5.502
Q-Input	I	1.005 ± 0.010	57.375 ± 10.407	49.362 ± 8.759
Q-Input	S	3.413 ± 2.319	9.632 ± 5.288	11.759 ± 3.915
Q-Input	A	0.941 ± 0.023	17.537 ± 3.245	15.105 ± 2.706
Q-Input	M	0.870 ± 0.050	7.616 ± 1.867	7.446 ± 1.841
Q-Weighted	C	1.158 ± 0.004	26.382 ± 1.957	26.341 ± 1.954
Q-Weighted	I	1.002 ± 0.008	26.541 ± 0.301	26.348 ± 0.305
Q-Weighted	S	5.492 ± 6.398	5.217 ± 2.207	8.972 ± 4.585
Q-Weighted	A	1.129 ± 0.034	27.361 ± 0.586	27.263 ± 0.611
Q-Weighted	M	1.007 ± 0.015	10.458 ± 0.735	10.373 ± 0.732
Q-Full	C	1.178 ± 0.124	53.832 ± 6.362	46.527 ± 5.331
Q-Full	I	1.005 ± 0.010	57.504 ± 10.485	49.480 ± 8.836
Q-Full	S	3.480 ± 2.270	9.667 ± 5.255	11.884 ± 3.682
Q-Full	A	1.128 ± 0.095	57.055 ± 7.896	49.307 ± 6.671
Q-Full	M	0.994 ± 0.019	15.162 ± 5.258	15.031 ± 5.219
Q-Shuffled	C	1.177 ± 0.124	53.371 ± 6.068	46.133 ± 5.080
Q-Shuffled	I	1.002 ± 0.002	55.037 ± 8.484	47.410 ± 7.125
Q-Shuffled	S	6.930 ± 2.513	4.549 ± 2.489	9.655 ± 1.835
Q-Shuffled	A	0.944 ± 0.034	16.985 ± 3.937	14.626 ± 3.287
Q-Shuffled	M	0.996 ± 0.014	11.230 ± 3.614	11.131 ± 3.608
Q-Constant	C	1.179 ± 0.124	53.784 ± 6.396	46.485 ± 5.367
Q-Constant	I	1.093 ± 0.053	55.106 ± 6.950	47.575 ± 5.825
Q-Constant	S	2.915 ± 1.667	30.170 ± 5.923	27.524 ± 3.861
Q-Constant	A	0.943 ± 0.024	17.488 ± 3.198	15.063 ± 2.668
Q-Constant	M	1.138 ± 0.185	31.582 ± 1.305	27.164 ± 0.930

接近 1 的比值不等于绝对 MSE 很小，也不证明闭环任务能够成功。所有比较均保留各自的干净测试分母；原始动作尺度和绝对误差请参照 CSV 数据。

B 完整中等强度测试矩阵：Koch

六组模型、五种训练条件的 Oracle 测试。各单元格为 $\bar{R} \pm s_{\text{train}}$ ，每格由 3 个训练种子和 3 个损坏种子组成。C/I/S/A/M 的含义见第 2 节。

模型	训练	图像	状态	混合
ACT-Lite	C	1.054 ± 0.039	28.149 ± 2.135	27.914 ± 2.071
ACT-Lite	I	1.003 ± 0.003	27.927 ± 2.396	27.635 ± 2.391
ACT-Lite	S	4.779 ± 5.967	13.718 ± 1.571	17.625 ± 4.913
ACT-Lite	A	1.037 ± 0.036	10.966 ± 1.113	10.882 ± 1.067
ACT-Lite	M	0.987 ± 0.003	11.548 ± 0.498	11.393 ± 0.478
Q-Input	C	1.069 ± 0.072	46.137 ± 4.472	39.760 ± 3.280
Q-Input	I	1.006 ± 0.009	46.288 ± 4.225	39.760 ± 3.021
Q-Input	S	1.019 ± 0.017	15.386 ± 1.470	15.248 ± 1.462
Q-Input	A	1.032 ± 0.058	16.782 ± 1.347	14.509 ± 1.118
Q-Input	M	0.778 ± 0.030	7.499 ± 0.543	7.293 ± 0.534
Q-Weighted	C	1.055 ± 0.041	28.108 ± 1.941	27.873 ± 1.877
Q-Weighted	I	1.003 ± 0.003	27.924 ± 2.411	27.632 ± 2.406
Q-Weighted	S	3.931 ± 4.339	13.930 ± 1.441	16.961 ± 3.403
Q-Weighted	A	1.051 ± 0.020	28.261 ± 1.011	28.004 ± 1.022
Q-Weighted	M	1.002 ± 0.001	16.969 ± 0.720	16.781 ± 0.699
Q-Full	C	1.069 ± 0.073	46.384 ± 4.630	39.968 ± 3.418
Q-Full	I	1.007 ± 0.009	46.115 ± 4.103	39.620 ± 2.931
Q-Full	S	1.019 ± 0.017	15.340 ± 1.471	15.204 ± 1.463
Q-Full	A	1.056 ± 0.066	46.728 ± 4.494	40.315 ± 3.239
Q-Full	M	1.004 ± 0.008	17.080 ± 1.012	16.921 ± 1.021
Q-Shuffled	C	1.070 ± 0.073	46.450 ± 4.563	40.023 ± 3.384
Q-Shuffled	I	1.000 ± 0.007	46.291 ± 4.589	39.772 ± 3.370
Q-Shuffled	S	1.016 ± 0.023	12.686 ± 0.673	12.587 ± 0.677
Q-Shuffled	A	1.032 ± 0.060	16.585 ± 1.240	14.350 ± 1.039
Q-Shuffled	M	1.001 ± 0.007	11.005 ± 0.470	10.863 ± 0.458
Q-Constant	C	1.069 ± 0.072	46.171 ± 4.714	39.790 ± 3.480
Q-Constant	I	1.069 ± 0.081	46.098 ± 3.875	39.728 ± 2.834
Q-Constant	S	1.050 ± 0.082	32.741 ± 2.710	28.310 ± 1.916
Q-Constant	A	1.030 ± 0.059	16.763 ± 1.501	14.493 ± 1.261
Q-Constant	M	1.024 ± 0.087	26.308 ± 2.051	22.666 ± 1.476

接近 1 的比值不等于绝对 MSE 很小，也不证明闭环任务能够成功。所有比较均保留各自的干净测试分母；原始动作尺度和绝对误差请参照 CSV 数据。

C 完整中等强度测试矩阵：xArm

六组模型、五种训练条件的 Oracle 测试。各单元格为 $\bar{R} \pm s_{\text{train}}$ ，每格由 3 个训练种子和 3 个损坏种子组成。C/I/S/A/M 的含义见第 2 节。

模型	训练	图像	状态	混合
ACT-Lite	C	1.000 ± 0.000	1.209 ± 0.028	1.191 ± 0.027
ACT-Lite	I	1.000 ± 0.001	1.211 ± 0.025	1.193 ± 0.024
ACT-Lite	S	1.009 ± 0.009	1.040 ± 0.006	1.043 ± 0.005
ACT-Lite	A	1.000 ± 0.000	1.056 ± 0.018	1.049 ± 0.017
ACT-Lite	M	1.000 ± 0.001	1.027 ± 0.003	1.024 ± 0.003
Q-Input	C	1.000 ± 0.000	1.105 ± 0.050	1.090 ± 0.041
Q-Input	I	1.000 ± 0.002	1.101 ± 0.053	1.087 ± 0.042
Q-Input	S	1.000 ± 0.001	1.040 ± 0.004	1.036 ± 0.004
Q-Input	A	1.000 ± 0.000	1.029 ± 0.008	1.025 ± 0.007
Q-Input	M	0.984 ± 0.016	1.012 ± 0.011	1.000 ± 0.020
Q-Weighted	C	1.000 ± 0.000	1.209 ± 0.028	1.191 ± 0.027
Q-Weighted	I	1.000 ± 0.001	1.212 ± 0.033	1.194 ± 0.031
Q-Weighted	S	1.009 ± 0.009	1.041 ± 0.008	1.044 ± 0.005
Q-Weighted	A	1.000 ± 0.000	1.131 ± 0.044	1.119 ± 0.042
Q-Weighted	M	1.000 ± 0.001	1.048 ± 0.001	1.042 ± 0.001
Q-Full	C	1.000 ± 0.000	1.103 ± 0.050	1.089 ± 0.041
Q-Full	I	1.000 ± 0.002	1.104 ± 0.054	1.090 ± 0.044
Q-Full	S	1.001 ± 0.001	1.040 ± 0.005	1.036 ± 0.005
Q-Full	A	1.000 ± 0.001	1.066 ± 0.022	1.056 ± 0.018
Q-Full	M	0.997 ± 0.002	1.037 ± 0.003	1.030 ± 0.002
Q-Shuffled	C	1.000 ± 0.000	1.104 ± 0.050	1.089 ± 0.041
Q-Shuffled	I	1.000 ± 0.000	1.104 ± 0.055	1.090 ± 0.046
Q-Shuffled	S	1.009 ± 0.007	1.040 ± 0.004	1.040 ± 0.005
Q-Shuffled	A	1.000 ± 0.000	1.026 ± 0.008	1.023 ± 0.007
Q-Shuffled	M	1.000 ± 0.001	1.024 ± 0.002	1.020 ± 0.001
Q-Constant	C	1.000 ± 0.000	1.103 ± 0.050	1.089 ± 0.041
Q-Constant	I	1.000 ± 0.000	1.103 ± 0.048	1.089 ± 0.039
Q-Constant	S	1.003 ± 0.003	1.052 ± 0.013	1.047 ± 0.014
Q-Constant	A	1.000 ± 0.000	1.027 ± 0.007	1.023 ± 0.005
Q-Constant	M	0.998 ± 0.003	1.035 ± 0.010	1.027 ± 0.009

接近 1 的比值不等于绝对 MSE 很小，也不证明闭环任务能够成功。所有比较均保留各自的干净测试分母；原始动作尺度和绝对误差请参照 CSV 数据。